CholecInstanceSeg YOLO26l-seg
全参数微调与模型规模对照实验报告

实验日期：2026年11月2日。large模型训练56轮，最佳第26轮；参照相同划分上的small与medium实验。

数据来源与实例标注

使用CholecInstanceSeg官方图像、实例JSON与元数据，作者项目为github.com/cai4cai/cholec_instance_seg。数据已经完成完整解码、实例关联、类别检查及YOLO多边形转换。本次训练沿用之前的数据划分与处理结果。

集合	图像	器械实例	无器械图像
train	26830	42716	2542
val	4284	6380	542
test	10819	15659	1830

训练、验证、测试分别包含45、18、22个视频编号，三组没有视频编号交集。验证集用于选择best.pt；训练完成后对该权重进行独立测试。

ID	类别	训练实例	验证实例	测试实例
0	grasper	25698	4017	8701
1	hook	12675	1759	4848
2	irrigator	1189	122	1109
3	clipper	899	99	326
4	bipolar	1762	270	526
5	scissors	450	113	149
6	snare	43	0	0

snare仅有43个训练实例，验证和测试均无实例；当前结果无法说明这一类别的泛化性能。

标注转换与核查

根据类别及group_id关联每个器械实例；使用Shapely修复几何并裁剪至图像范围，通过Ultralytics官方merge_multi_segment处理离散轮廓，输出归一化YOLO多边形。独立验证逐张解码输出图像，从实际TXT还原掩膜并核对实例数、类别与尺寸。

项目	已完成核查结果
完整图像 / 实例	41,933 / 64,755
图像尺寸	854×480、1920×1080
未配对 / 核查失败	0 / 0
平均还原IoU	0.99971728
面积加权还原IoU	0.99989545
最小实例还原IoU	0.87465691
还原IoU低于0.95	31个实例
未解释像素差异	0

上述IoU描述标签表示误差；模型预测性能使用后续的验证和测试指标。完整逐实例转换记录及低IoU清单已保存到data/。

实际服务器环境

项目	实际设置
GPU / CPU / 内存	RTX 4090 24GB / i9-14900K / 128GB
系统	Linux-6.17.0-1025-oem-x86_64-with-glibc2.39
Python / Ultralytics	3.12.3 / 8.4.190
PyTorch / torchvision	2.14.1+cu126 / 0.29.1+cu126
CUDA运行时 / 驱动	12.6 / 580.105.08
PyTorch可见显存	23.516GiB

模型与训练配置

从官方COCO预训练yolo26l-seg.pt开始七类别全参数微调。实际训练结构含31,384,201个参数，freeze=0；AMP检查通过。该计数来自七类别训练结构，与融合后推理结构的计数口径不同。

参数	实际设置
计划 / 完成 / 最佳Epoch	150 / 56 / 26
早停条件	patience=30
Image Size / Batch Size / nbs	640 / 16 / 64
Device / AMP / Workers	CUDA:0 / True / 8
优化器 / 初始学习率	MuSGD / 0.01
momentum / weight_decay	0.9 / 0.0005
Warmup / lrf / cos_lr	3.0轮 / 0.01 / False
Seed / deterministic	42 / True
Mosaic / close_mosaic	1.0 / 10
fliplr / translate / scale	0.5 / 0.1 / 0.5
mask_ratio / overlap_mask	4 / True
save_period / cache	10 / False

与之前small实际配置的24项参数已逐项核对一致，涵盖数据路径、优化器、学习率、增强、批量、随机种子和分割参数。此前small与medium也已核对这24项。各模型分别从对应的官方COCO权重开始。

close_mosaic按150轮计划在最后10轮关闭；本次第56轮提前停止，未进入这一阶段。预热之后梯度累积约4个批次，精确优化器更新次数未单独记录。

训练耗时与保存

北京时间19:05启动，约23:43结束，累计16,649.9秒，约4.625小时。每轮平均297.32秒，中位数296.90秒。日志中的保留显存最高观测值约22.5GiB，显示值有舍入。

每轮1,677个训练批次、134个验证批次；56轮共93,912个训练批次，图像呈现1,502,480次。按3.41元/小时折算正式训练约15.77元，其余流程另计。

最佳模型验证指标

best.pt来自第26轮。下表整体指标取自results.csv第26轮原始记录，验证集为4,284张图像、6,380个实例。训练结束后的best.pt复验结果与该记录接近。

指标	Box	Mask
Precision	0.96037	0.96093
Recall	0.84905	0.84631
mAP50	0.91125	0.90765
mAP50-95	0.81624	0.73870

检测框逐类别结果

类别	实例	Precision	Recall	mAP50	mAP50-95
grasper	4017	0.944	0.929	0.967	0.815
hook	1759	0.988	0.984	0.993	0.907
irrigator	122	0.955	0.934	0.961	0.885
clipper	99	0.989	0.933	0.974	0.919
bipolar	270	0.925	0.872	0.926	0.785
scissors	113	0.961	0.442	0.647	0.589

分割掩膜逐类别结果

类别	实例	Precision	Recall	mAP50	mAP50-95
grasper	4017	0.942	0.923	0.958	0.697
hook	1759	0.987	0.984	0.993	0.881
irrigator	122	0.958	0.934	0.961	0.847
clipper	99	0.989	0.932	0.974	0.879
bipolar	270	0.918	0.863	0.918	0.618
scissors	113	0.969	0.442	0.643	0.511

逐类别值来自原生日志，保留显示精度。scissors验证召回约0.442、Mask mAP50-95约0.511；bipolar约0.618。总体指标无法确定具体失败原因，snare因无验证实例没有列入。

训练曲线与提前停止

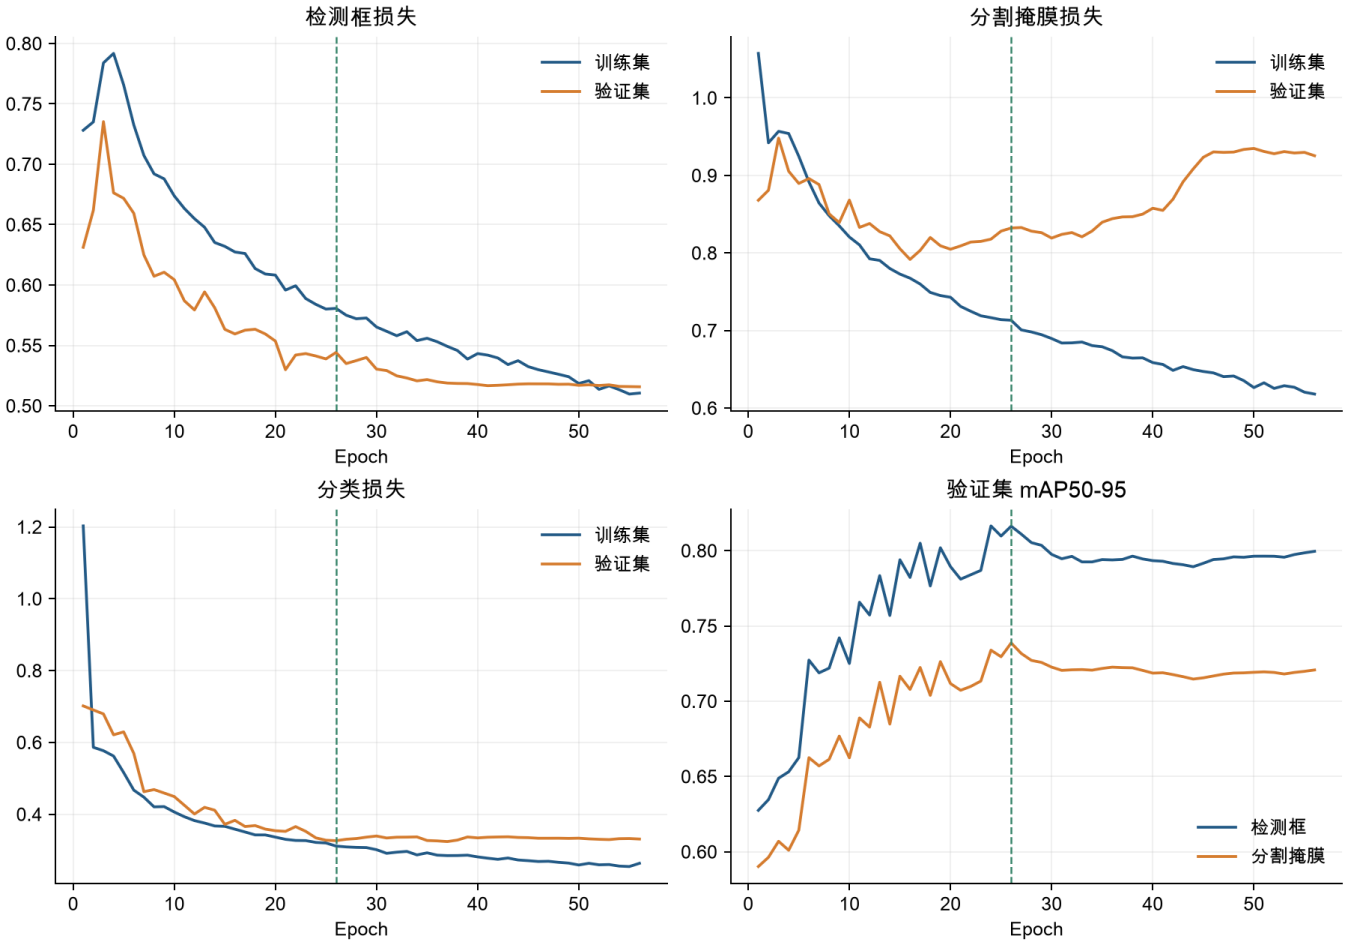


图1：56轮真实训练与验证曲线，绿色虚线表示最佳第26轮。数值直接读取原始CSV，没有填补或平滑。

第26至56轮，训练Mask Loss从0.71319降至0.61805，验证Mask Loss从0.83214变为0.92533，验证Mask mAP50-95从0.73870变为0.72076。训练拟合继续改善，验证指标没有同步改善，呈现过拟合迹象。

第26轮后连续30轮没有刷新验证fitness，因此第56轮正常提前停止。当前框架的分割fitness为Box与Mask mAP50-95之和；最佳轮次已用CSV和原生早停日志共同核对。独立测试和预测均采用best.pt。

本次只训练一个随机种子。当前结果不能量化模型容量、类别不均衡及标注边界误差各自的影响。

独立测试与三种模型对照

使用同一独立测试集10,819张图像、15,659个实例。large采用验证集选出的best.pt；测试batch=16、imgsz=640。small、medium取自此前相同入口与设置下的完整测试，未重新训练。

指标	YOLO26s	YOLO26m	YOLO26l
Box Precision	0.93537	0.95092	0.91992
Box Recall	0.88338	0.87917	0.88456
Box mAP50	0.93016	0.93611	0.92865
Box mAP50-95	0.83570	0.84526	0.83708
Mask Precision	0.93485	0.95141	0.92917
Mask Recall	0.87939	0.87627	0.87094
Mask mAP50	0.92682	0.93283	0.92490
Mask mAP50-95	0.76066	0.76502	0.75943

large测试集逐类别掩膜结果

类别	实例	Precision	Recall	mAP50	mAP50-95
grasper	8701	0.919	0.873	0.932	0.652
hook	4848	0.991	0.987	0.994	0.882
irrigator	1109	0.961	0.902	0.959	0.806
clipper	326	0.979	0.859	0.960	0.855
bipolar	526	0.950	0.907	0.948	0.683
scissors	149	0.775	0.698	0.756	0.679

large测试Mask mAP50-95为0.75943，比medium低约0.559个百分点。当前单次实验未观察到large带来总体分割提升，尚未进行多随机种子显著性检验。

逐类别掩膜mAP来自原生日志，只有显示精度；Ultralytics逐类别JSON中无前缀的mAP字段为检测框指标。验证与测试视频不同，分数差异不表示测试时进行了额外训练。

推理计时与模型规模

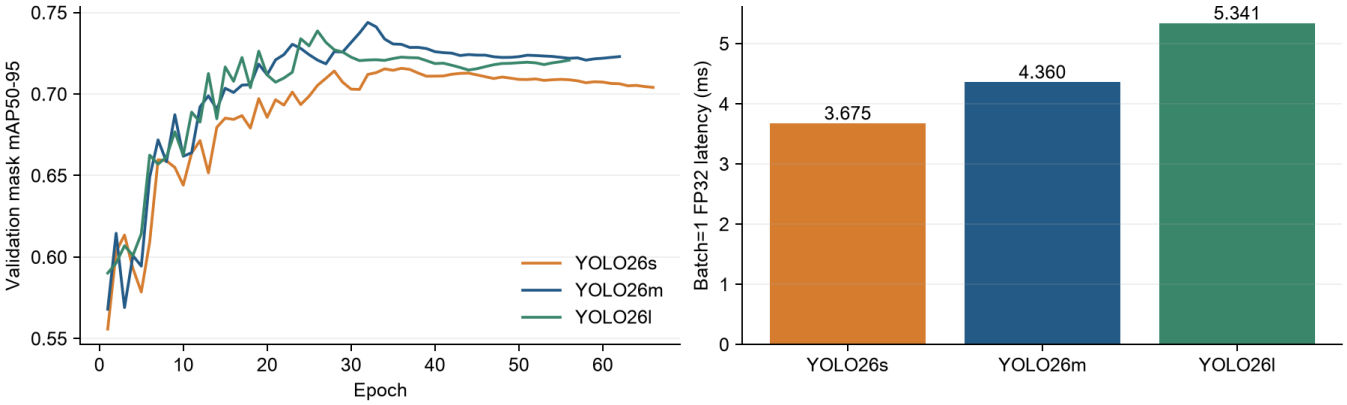


图2：三种模型的完整验证曲线及Batch=1、FP32平均延迟。

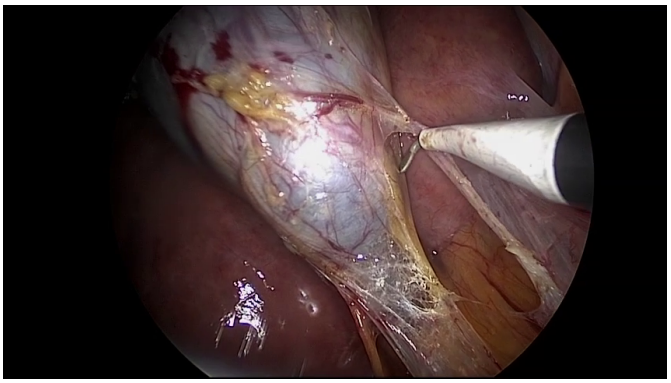
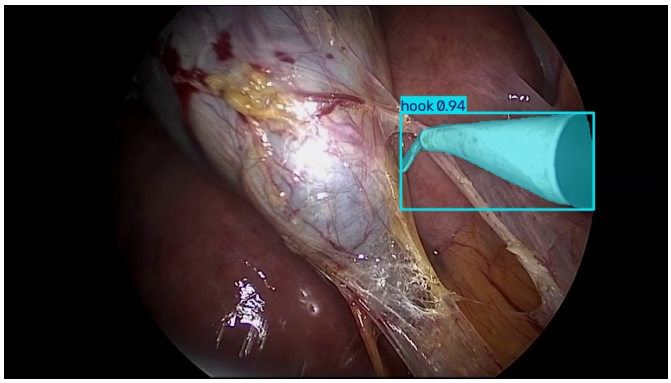
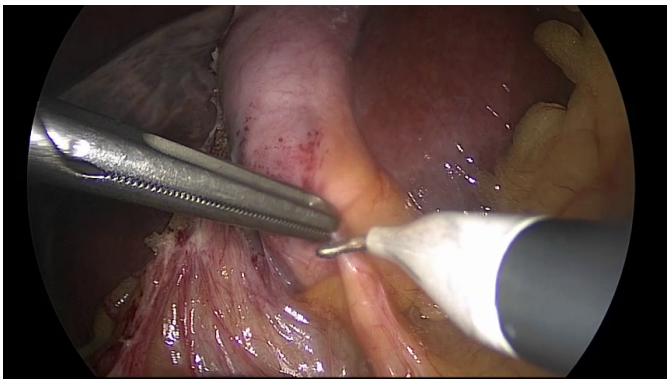
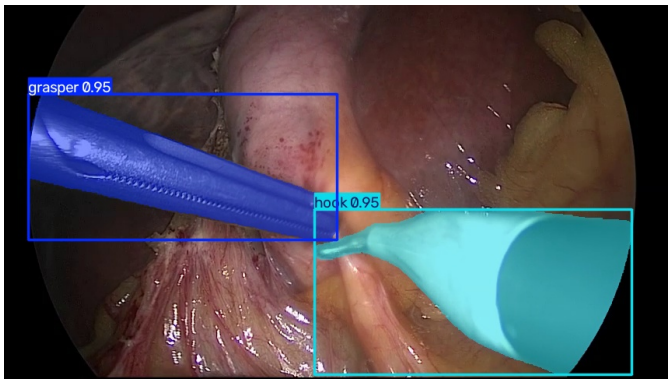
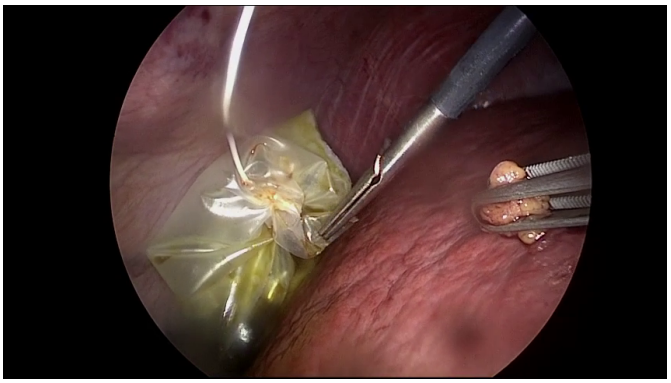
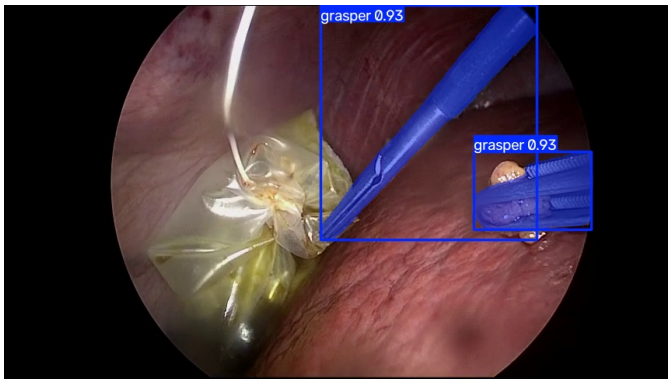
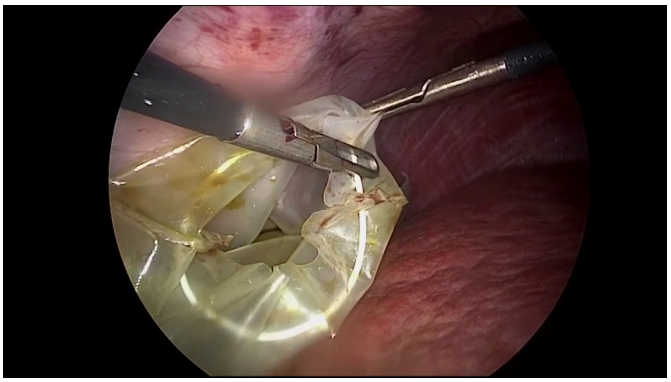
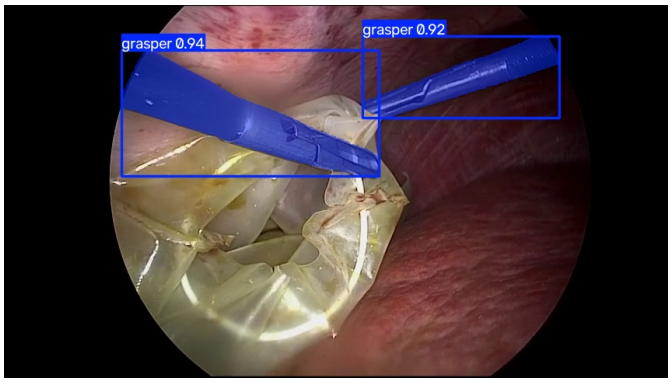
指标	YOLO26s	YOLO26m	YOLO26l
实际轮数 / 最佳轮次	66 / 36	62 / 32	56 / 26
训练耗时（小时）	2.880	4.594	4.625
验证Mask mAP50-95	0.71575	0.74391	0.73870
测试Mask mAP50-95	0.76066	0.76502	0.75943
平均延迟（ms）	3.675	4.360	5.341
中位延迟（ms）	3.676	4.345	5.426
P95延迟（ms）	3.804	4.571	5.508
折算FPS	272.093	229.360	187.237

三种模型均使用随机种子42选择的相同50张验证图像、10张预热、Batch=1、FP32和CUDA同步计时；读取的来源清单已核对一致。包含预处理、推理和后处理，排除文件解码、绘制及视频编码。small、medium沿用先前计时，large在训练结束后单独计时，运行时段不同。

每种模型只执行一组计时，未给出重复测量置信区间。折算FPS不代表完整视频处理速度。本次medium在测试分割指标上最高，small平均延迟最低；结论限定于当前数据划分与测量条件。

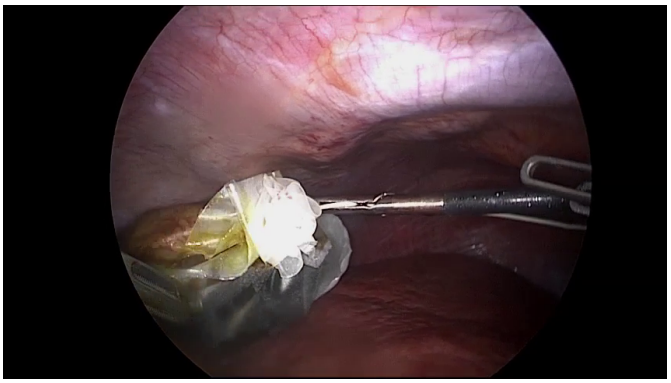
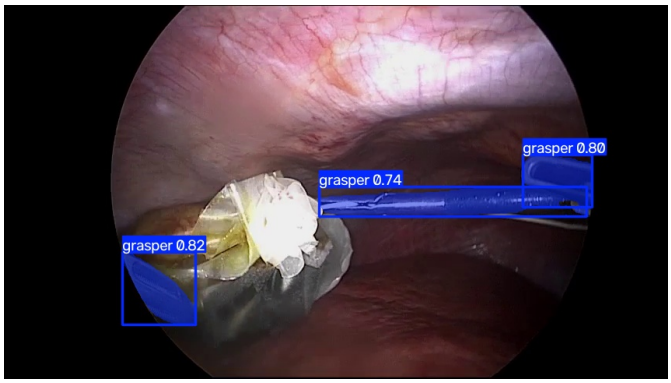
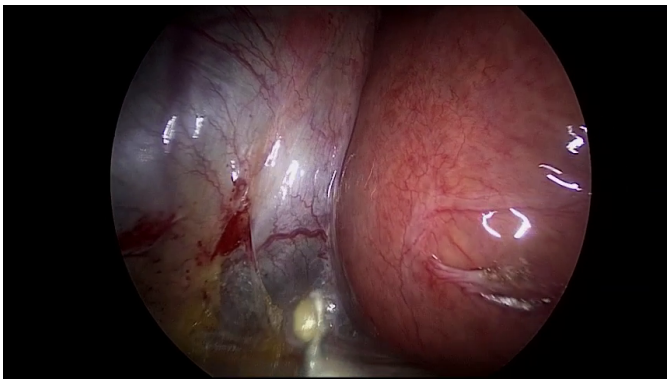
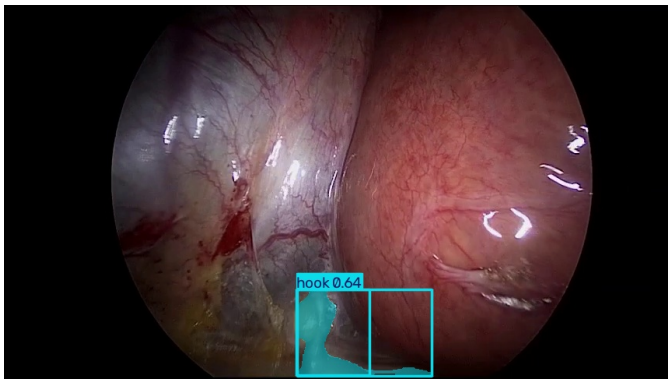
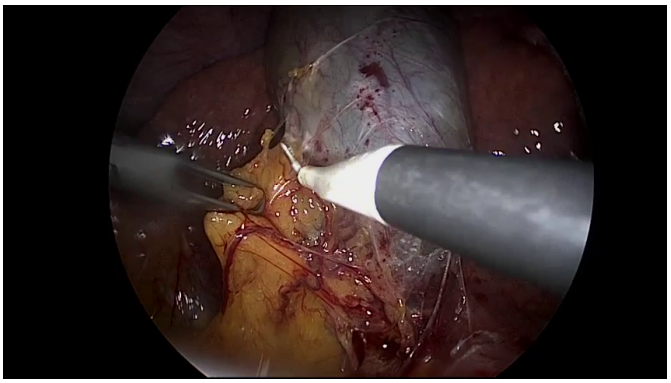
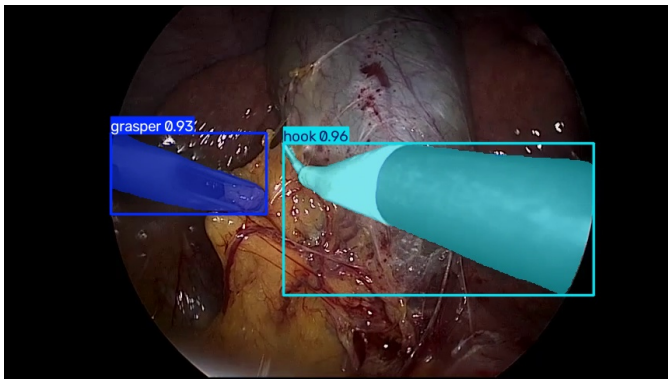
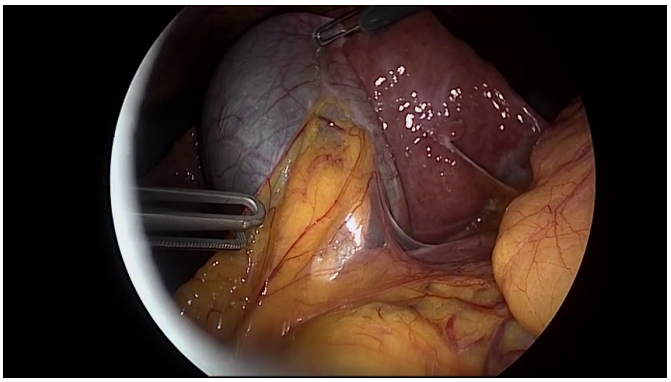
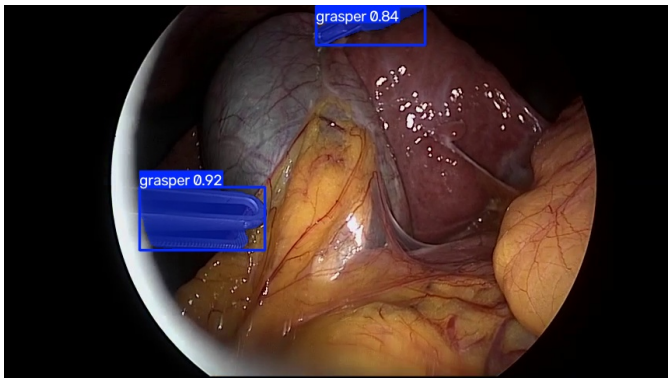
预测图片示例（一）

使用与此前报告相同的20张固定验证样本，按抽样顺序展示前8张。左侧原图，右侧为large第26轮best.pt的真实预测，imgsz=640、conf=0.25，在Mac CPU上生成。

原始图像	YOLO26l-seg预测
	
样例01 | 预测1个器械实例	
	
样例02 | 预测2个器械实例	
	
样例03 | 预测2个器械实例	
	
样例04 | 预测2个器械实例	

预测图片示例（二）

使用与此前报告相同的20张固定验证样本，按抽样顺序展示前8张。左侧原图，右侧为large第26轮best.pt的真实预测，imgsz=640、conf=0.25，在Mac CPU上生成。

原始图像	YOLO26l-seg预测
	
样例05 | 预测3个器械实例	
	
样例06 | 预测2个器械实例	
	
样例07 | 预测2个器械实例	
	
样例08 | 预测2个器械实例	

权重、归档与复现

best.pt对应第26轮，last.pt对应第56轮，均已清理优化器状态。阶段检查点共六个：epoch0.pt、epoch10.pt至epoch50.pt，对应完成第1、11、21、31、41、51轮。最新epoch50.pt保留优化器状态；恢复后仍受原早停条件控制。

材料	实验归档相对路径
最佳 / 最终权重	weights/best.pt、weights/last.pt
阶段检查点	checkpoints/epoch50.pt等六个文件
代码与可迁移配置	code/scripts/、code/configs/
实际配置与环境	config/args.yaml、config/environment.json、依赖清单
逐轮记录 / 验证	metrics/results.csv、best_epoch_validation_metrics.json
独立测试 / 推理计时	metrics/test-l.json、metrics/benchmark.json
三模型对照	metrics/comparison.json
原始日志 / 数据核查	logs/、data/

完整归档位于experiments/2026-11-02_yolo26l_cholec/。数据、类别与代码材料保留在本地项目中；报告材料保存固定图像和真实预测JSON。

```
.venv/bin/python scripts/download_weights.py --model yolo26l-seg
.venv/bin/python scripts/run.py train \
--config configs/rtx4090.yaml \
--weights weights/yolo26l-seg.pt --batch 16 \
--name yolo26l-reproduce
```

发布材料与实验限制

GitHub目录包含代码、配置、数据核查摘要、逐轮结果、日志与本报告。Hugging Face目录包含large最佳、最终及六个阶段权重，模型说明、类别映射和评估结果。当前只准备本地文件，尚未远程发布。

仅有一个训练随机种子，尚未进行跨医院、跨设备或外部视频验证。snare缺少验证和测试实例，类别数量不均衡。预测样例用于展示输出，定量结论依据完整验证集与独立测试集。