CholecInstanceSeg YOLO26m-seg 全参数微调实验报告

实验日期：2026年11月2日。训练完成62轮，最佳模型来自第32轮。

数据来源与标注

使用CholecInstanceSeg公开数据的官方图像、实例标注及元数据。图像源文件为cholecinstance_seg_reference_image_set.zip，标注源文件为cholecinstanceseg.zip，元数据为cholecinstanceseg_metadata.csv。作者项目为github.com/cai4cai/cholec_instance_seg，原始文件与转换后的完整数据保存在本地项目datasets/cholecinstanceseg/。

本次逐张解码并核对全部41,933帧图像，检查图像与标注的配对、尺寸、类别和实例编号。原始实例由类别与group_id共同确定，同类别的多个器械分别保留。共核查64,755个实例，未配对图像为0。原始标注保留，训练使用转换后的YOLO多边形标签。

集合	图像数	实例数	无器械图像	视频编号数
train	26830	42716	2542	45
val	4284	6380	542	18
test	10819	15659	1830	22

沿用作者提供的序列划分；按文件名中的视频编号进一步核查，训练、验证和测试的视频编号没有交集。无器械图像保留为空标签样本。训练使用全部训练集，验证集用于模型选择，独立测试集尚未执行评估。

类别与实例分布

ID	器械类别	英文名称	训练实例	验证实例	测试实例
0	抓钳	grasper	25698	4017	8701
1	电钩	hook	12675	1759	4848
2	冲洗吸引器	irrigator	1189	122	1109
3	施夹器	clipper	899	99	326
4	双极器械	bipolar	1762	270	526
5	剪刀	scissors	450	113	149
6	圈套器	snare	43	0	0

grasper与hook占训练实例的主要部分。snare只有43个训练实例，验证集与测试集均为0；报告中的总体验证指标不能用于说明snare的识别或分割能力。

标注转换与完整性核查

转换程序按类别和group_id合并同一器械的轮廓，使用Shapely修复无效几何并裁剪到图像范围；保留内部孔洞、离散区域及需要保留的细线。多段轮廓使用Ultralytics官方merge_multi_segment连接，输出归一化的YOLO分割坐标。

独立验证重新读取实际保存的TXT标签，使用官方polygon2mask还原掩膜，与原始实例标注逐实例比较，并核对类别、图像尺寸、实例关联、文件数量和视频划分。原始图像尺寸为854×480、1920×1080；下表的转换IoU在对应原始图像网格上计算。

核查项目	结果
全部实例平均还原IoU	0.99971728
按实例面积加权还原IoU	0.99989545
最小实例还原IoU	0.87465691
还原IoU低于0.95的实例	31 / 64,755
未解释像素差异	0
转换检查失败 / 未配对图像	0 / 0
官方数据加载器核对	三个集合均无图像或实例丢失

31个较低IoU实例主要受到小实例、离散轮廓连接线与栅格化的影响，记录在data/low_iou_instances.json。转换几何的连接前检查与连接线新增像素分别核查。转换还原IoU描述标签表示误差，与模型预测的分割IoU含义不同。

GPU与软件环境

项目	实际环境
操作系统	Linux-6.17.0-1025-oem-x86_64-with-glibc2.39
CPU / 内存	Intel Core i9-14900K / 128GB
GPU	NVIDIA GeForce RTX 4090
NVIDIA驱动	580.105.08（服务器登录检查）
Python	3.12.3
PyTorch / torchvision	2.14.1+cu126 / 0.29.1+cu126
CUDA运行时	12.6
Ultralytics	8.4.190
PyTorch可见显存	23.516 GiB
CUDA前向与反向检查	通过，计算结果与梯度均为有限值

依赖在Linux虚拟环境中安装；完整服务器版本记录为config/server-requirements.lock.txt，安装日志为logs/setup.log。

模型与训练配置

从Ultralytics官方COCO预训练yolo26m-seg.pt开始新的七类别分割实验。训练日志记录329层、26,980,745个参数与同数量梯度参数，freeze=0。最终验证时的融合结构为146层、23,512,865个参数；训练结构与融合推理结构的参数数量分别记录。

参数	实际设置
Task / 模型	segment / YOLO26m-seg
最大Epoch / 实际Epoch	150 / 62
最佳Epoch / 提前停止	32 / patience=30
Image Size / Batch Size	640 / 16
nbs / 梯度累积	64 / 预热后约4个批次
Optimizer	MuSGD，显式指定
lr0 / momentum / weight_decay	0.01 / 0.9 / 0.0005
AMP / CUDA	True / device 0
Workers / Seed	8 / 42
Freeze / deterministic	0 / True
Warmup Epoch	3.0
学习率安排	线性衰减，cos_lr=False，lrf=0.01
Mosaic / close_mosaic	mosaic=1.0，close_mosaic=10
其他主要增强	fliplr=0.5，translate=0.1，scale=0.5
mask_ratio / overlap_mask	4 / True
图像缓存	cache=False
阶段检查点	save_period=10
模型选择	Ultralytics验证fitness，保存best.pt

实际完整参数保存在config/args.yaml。优化器初始化日志记录144组无衰减权重、164组带0.0005衰减的权重及164组偏置；不同参数组的学习率不完全相同，实际值见results.csv。

close_mosaic=10按150轮计划在最后10轮关闭Mosaic；本次第62轮提前停止，没有进入该阶段。日志中没有发生正式训练的Mosaic关闭事件。

正式训练从原始COCO预训练权重加载，三轮诊断测量的权重未用于正式训练。预测示例统一使用第32轮的best.pt。

训练过程与耗时

训练于北京时间2026年11月2日约02:34在tmux会话yolo-train中启动，约07:10完成。原生日志记录62轮耗时4.594小时；results.csv累计时间为16,538.3秒。按3.41元/小时折算，正式训练费用约15.67元，上传、安装和诊断测量费用另计。

项目	实际结果
每轮训练批次 / 验证批次	1,677 / 134
62轮训练批次总数	103,974
训练图像呈现次数	1,663,460
每轮平均 / 中位耗时	266.75 / 266.30 秒
最快 / 最慢轮次耗时	265.97 / 285.38 秒
完整逐轮数值检查	62轮全部损失、指标和学习率均为有限值

批次迭代次数与优化器更新次数分别计算。预热后约每4个训练批次累积一次梯度；预热期间累积步长变化，未从批次数量推断精确优化器更新总数。

Epoch	每轮秒数	训练Box Loss	训练Mask Loss	验证Mask Loss	Mask mAP50-95
1	285.38	0.73587	1.06463	0.88827	0.56804
10	266.67	0.67108	0.81345	0.85083	0.66185
20	266.57	0.61211	0.74120	0.81661	0.71175
30	266.23	0.56768	0.68726	0.84191	0.73161
32	266.57	0.56109	0.68147	0.84270	0.74391
40	266.20	0.54463	0.65920	0.86761	0.72596
50	266.50	0.52266	0.62889	0.90506	0.72290
60	266.30	0.50568	0.61678	0.92923	0.72194
62	266.20	0.50609	0.60652	0.93413	0.72295

显存记录的统计范围

正式训练前三轮的外部GPU采样记录整卡占用峰值18,173MiB，约17.75GiB。完整62轮训练日志显示，PyTorch保留显存的最高观测值约21.4GiB，出现在第53轮，终端数值存在舍入。两项统计范围与口径不同，前三轮整卡采样没有覆盖完整训练。

本次62轮训练正常结束，未发生CUDA显存溢出。报告不把前三轮的显存采样值当作整个实验的整卡峰值。

最佳模型验证指标

模型选择使用完整4,284张验证图像、6,380个实例。下表为results.csv第32轮的原始精度记录，数值范围0-1。训练结束后框架自动重新验证best.pt，日志中的整体结果分别约为Box mAP50-95=0.825、Mask mAP50-95=0.744，与逐轮记录接近。

指标	Box	Mask
Precision	0.97058	0.96976
Recall	0.84221	0.84120
mAP50	0.91397	0.91084
mAP50-95	0.82479	0.74391

以下逐类别结果来自训练结束后的best.pt原生验证日志，保留其显示精度，末尾补零用于排版。snare在验证集中没有真值实例，逐类别表不列入该类别。

检测框逐类别结果

类别	验证实例	Precision	Recall	mAP50	mAP50-95
grasper	4017	0.950	0.930	0.965	0.817
hook	1759	0.990	0.986	0.994	0.913
irrigator	122	0.958	0.934	0.968	0.888
clipper	99	0.979	0.926	0.978	0.928
bipolar	270	0.966	0.848	0.915	0.789
scissors	113	0.980	0.432	0.665	0.612

分割掩膜逐类别结果

类别	验证实例	Precision	Recall	mAP50	mAP50-95
grasper	4017	0.950	0.929	0.956	0.703
hook	1759	0.990	0.986	0.994	0.882
irrigator	122	0.958	0.932	0.964	0.854
clipper	99	0.979	0.926	0.978	0.873
bipolar	270	0.962	0.844	0.908	0.630
scissors	113	0.980	0.432	0.665	0.524

总体Precision较高，Recall低于Precision。scissors的验证召回约0.432、Mask mAP50-95约0.524，低于其他已评估类别；bipolar的Mask mAP50-95约0.630。该差异提示需要重点检查这些类别的漏检及分割，但仅凭汇总指标无法确定具体失败原因。

Loss与收敛分析

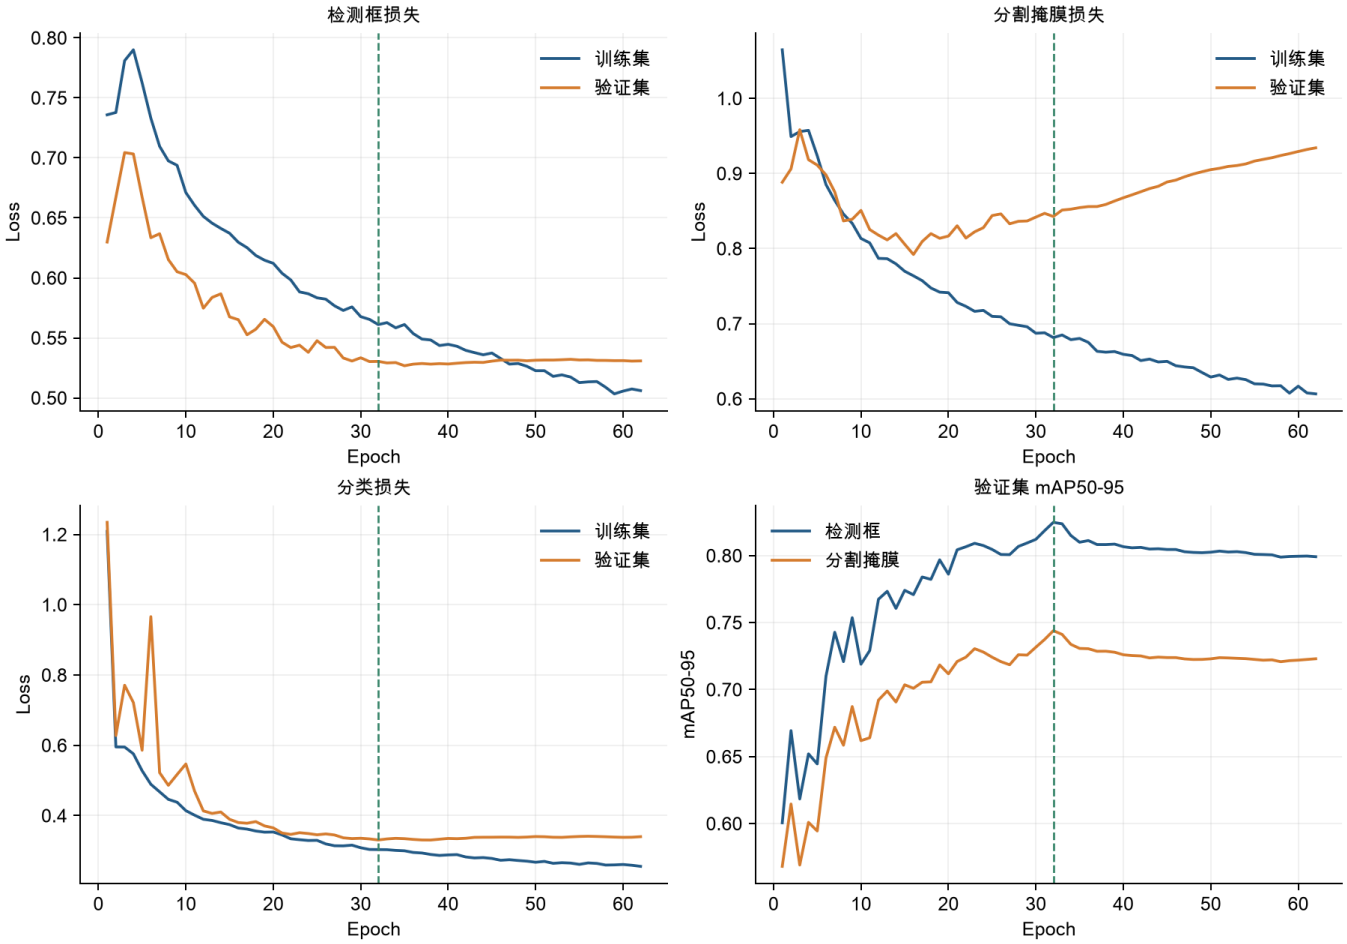


图1：62轮真实训练与验证曲线。绿色虚线标出最佳第32轮；曲线直接来自results.csv，没有模拟、填补或平滑。

第32至62轮，训练Mask Loss从0.68147下降到0.60652，验证Mask Loss从0.84270上升到0.93413，验证Mask mAP50-95从0.74391下降到0.72295，下降约2.10个百分点。训练拟合继续改善，但验证表现没有同步改善，呈现过拟合迹象。

训练Box Loss同期从0.56109降至0.50609，Box mAP50-95从0.82479降至0.79911。模型保存与停止由验证fitness控制，不能用训练损失持续下降推断需要更多轮次。

第32轮之后连续30轮没有刷新最佳fitness，因此第62轮触发提前停止。该结果说明本次训练达到设置的停止条件；它没有证明所有训练配置都应固定为62轮，也没有证明继续到150轮能够提升验证性能。

最佳轮次之后的验证变化

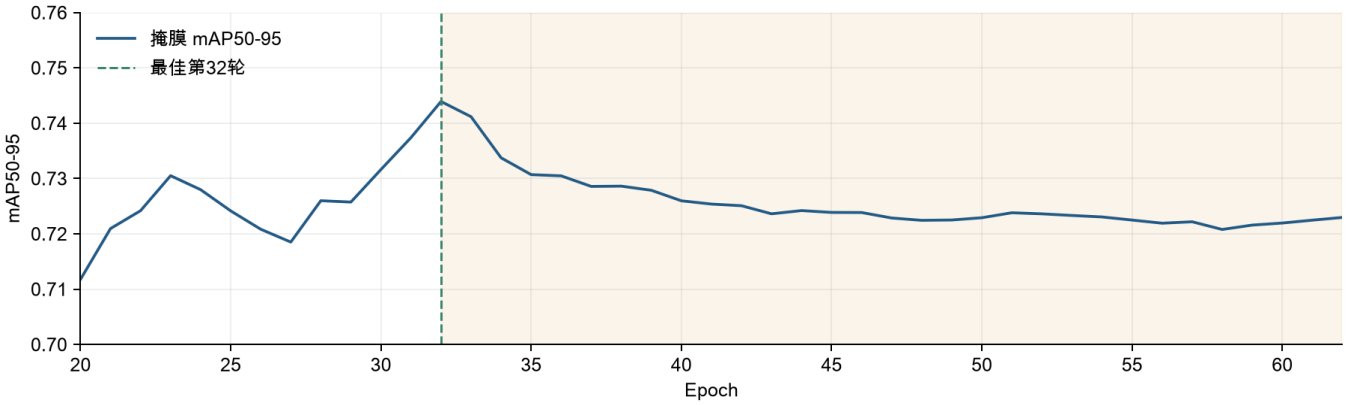


图2：第20至62轮的验证Mask mAP50-95局部曲线。阴影覆盖最佳第32轮之后的观测区间。

项目	第32轮 best	第62轮 last
训练Mask Loss	0.68147	0.60652
验证Mask Loss	0.84270	0.93413
Mask mAP50	0.91084	0.88115
Mask mAP50-95	0.74391	0.72295

正式训练全程使用同一最大轮次计划与Mosaic配置；第32轮后指标退化不能解释为关闭Mosaic造成的突变。类别不均衡、视频场景差异与小实例边界误差都可能影响验证表现，当前实验没有单独控制这些因素来确定因果贡献。

验证阶段GPU推理耗时

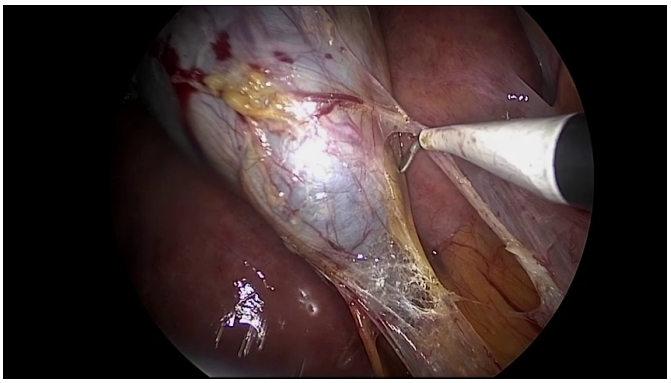
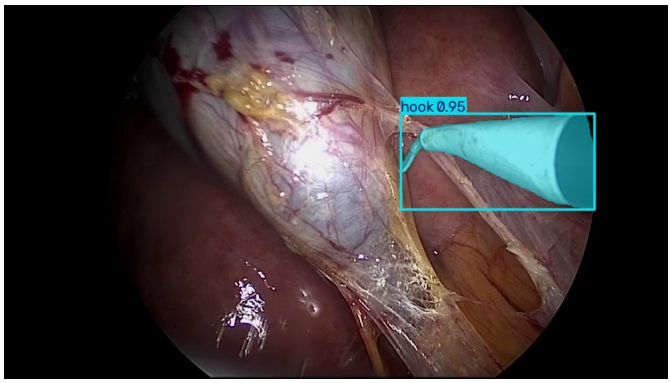
阶段	原生验证日志显示的每图平均耗时
预处理	0.1 ms
模型推理	1.6 ms
损失计算	0.0 ms（显示精度）
后处理	0.3 ms

以上来自训练结束后best.pt对完整验证集的原生评估，设置的验证批量为32。该记录没有提供Batch=1同步计时、P95延迟或完整视频处理速度，报告不据此给出单帧实时FPS。

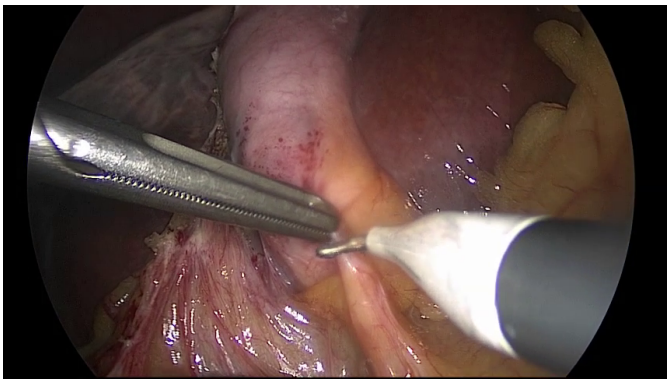
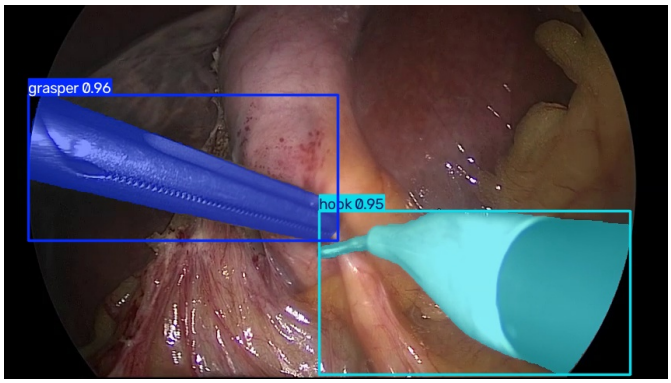
本报告另外在Mac CPU上生成20张验证图片的真实预测，用于展示模型输出。该步骤与服务器GPU验证的计时口径不同，未作为GPU性能基准。

预测图片示例（一）

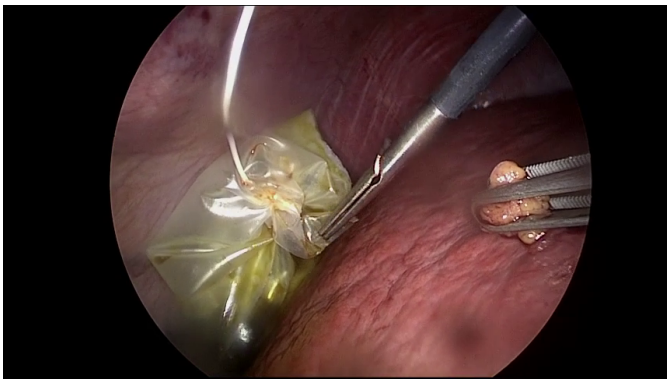
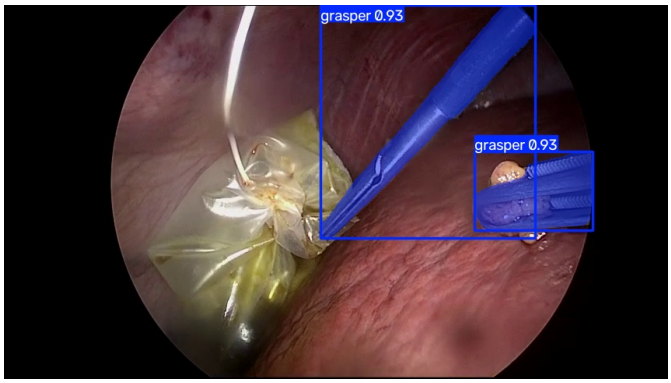
固定随机种子42，从完整验证集随机抽取20张。报告按抽样顺序展示前8张，左侧原图，右侧为本次best.pt预测的边界框、类别、置信度和实例掩膜；conf=0.25，imgsz=640。

原始图像	模型预测
	

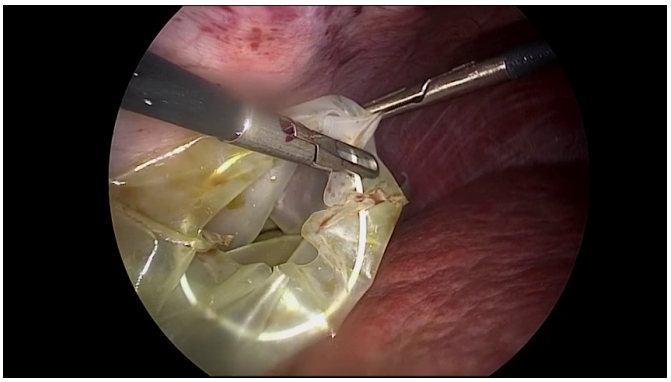
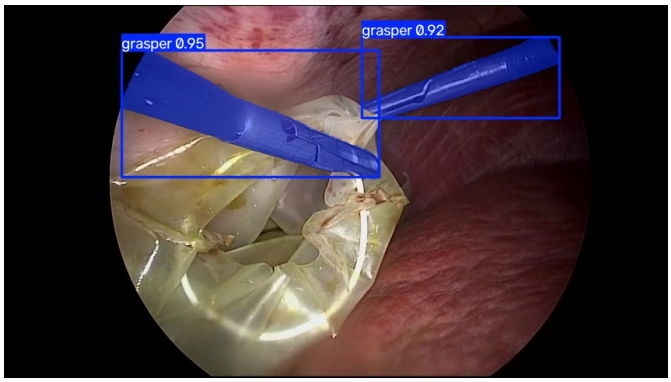
样例01 | VID23 | 预测1个实例

样例02 | VID11 | 预测2个实例

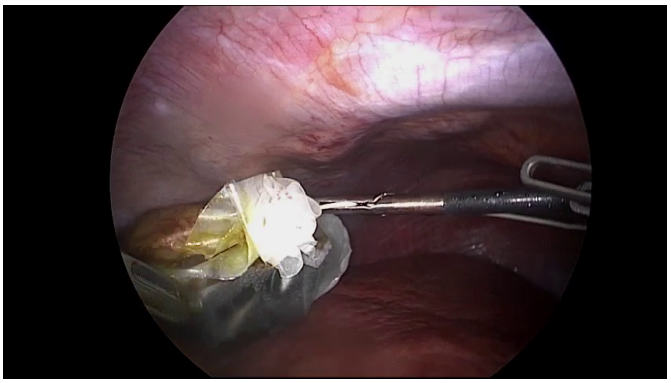
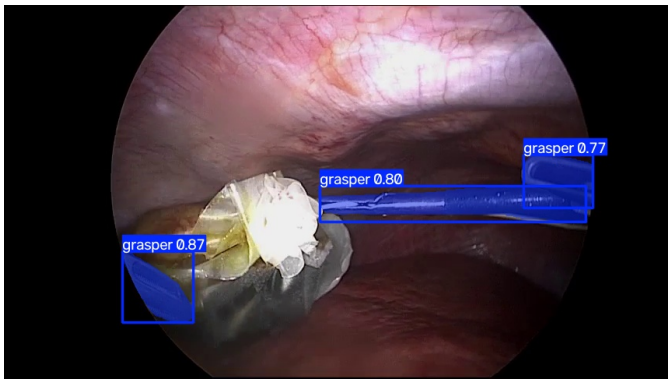
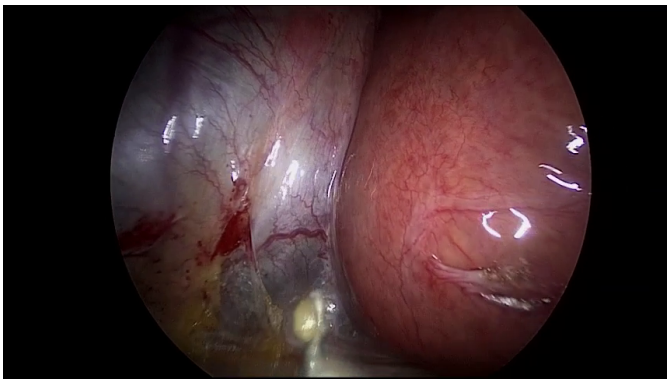
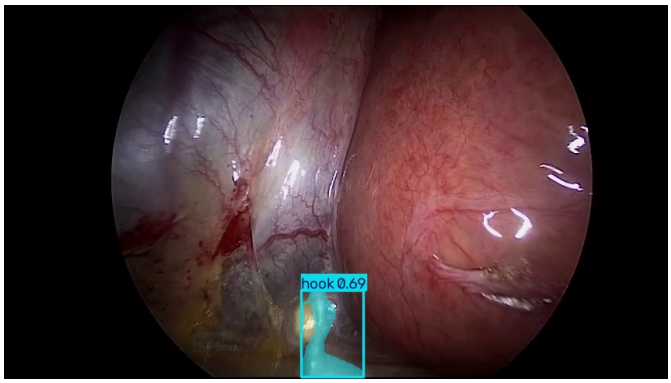
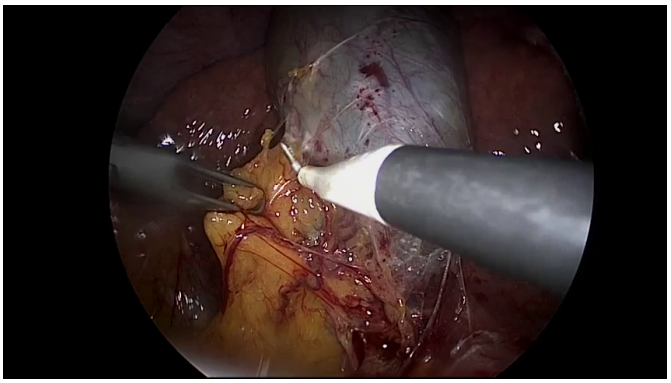
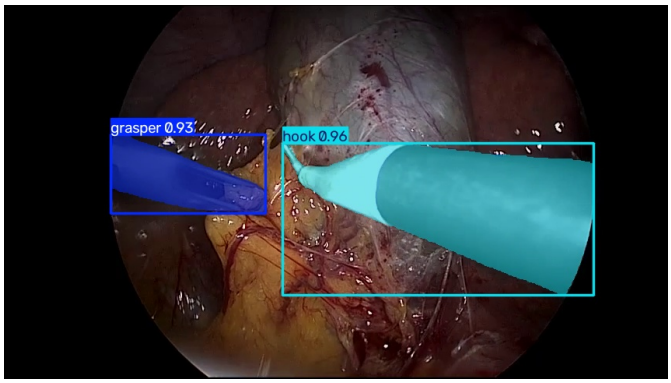
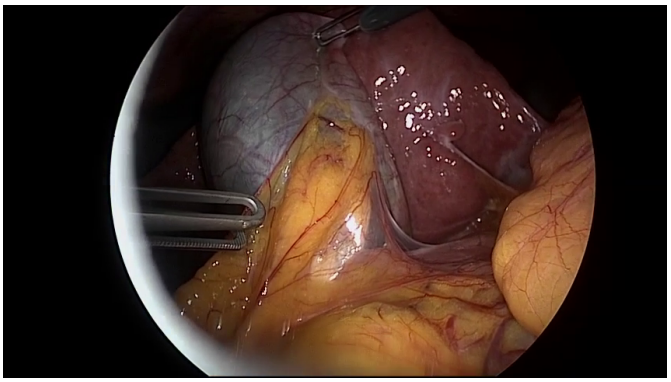
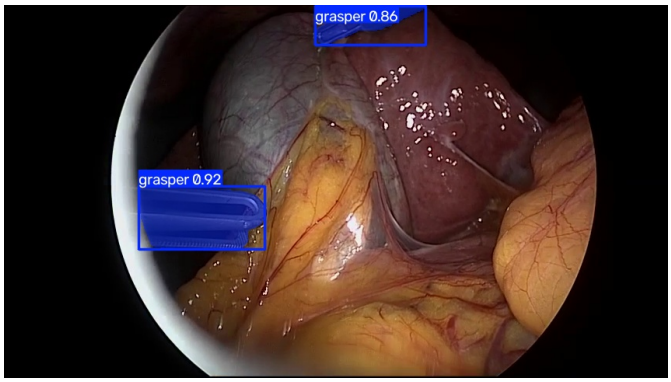
样例03 | VID23 | 预测2个实例

样例04 | VID23 | 预测2个实例

预测图片示例（二）

固定随机种子42，从完整验证集随机抽取20张。报告按抽样顺序展示前8张，左侧原图，右侧为本次best.pt预测的边界框、类别、置信度和实例掩膜；conf=0.25，imgsz=640。

原始图像	模型预测
	
样例05 | VID23 | 预测3个实例	
	
样例06 | VID23 | 预测1个实例	
	
样例07 | VID23 | 预测2个实例	
	
样例08 | VID23 | 预测2个实例	

权重、日志与复现

best.pt来自第32轮，last.pt来自第62轮，文件均约54.48MB。另保存epoch0.pt、epoch10.pt、epoch20.pt、epoch30.pt、epoch40.pt、epoch50.pt、epoch60.pt，共7份阶段检查点，每份约162.5MB。原生文件名使用从0开始的轮次编号，分别对应完成第1、11、21、31、41、51、61轮。

本地已读取验证best.pt和epoch60.pt。best.pt与last.pt在正常结束后清理优化器状态；epoch60.pt保留完整优化器状态，对应已完成61轮。恢复阶段检查点仍受原提前停止配置控制。

材料	归档相对路径
最佳 / 最终权重	weights/best.pt、weights/last.pt
完整续训检查点	checkpoints/epoch60.pt
实际配置 / Linux依赖	config/args.yaml、config/server-requirements.lock.txt
62轮指标 / 最佳轮次指标	metrics/results.csv、metrics/best_epoch_validation_metrics.json
训练日志 / 简明日志	logs/rtx4090-train.log、logs/training_events.txt
数据转换与验证记录	data/conversion.jsonl、data/verification.json
训练代码与配置快照	code/scripts/、code/configs/
文件清单与备份核查	archive_inventory.json、verification.json

上表归档根目录为experiments/2026-11-02_yolo26m_cholec/。在具有相同CUDA环境及完整数据的yolofinetune根目录执行下列训练命令，使用独立实验名称。

```
.venv/bin/python scripts/run.py train \
--config configs/rtx4090.yaml --batch 16 \
--name rtx4090-reproduce
```

实验限制与后续评估

独立测试集10,819帧尚未评估，报告结论限定于当前验证划分。当前模型未进行不同医院、设备或手术场景的外部验证；验证集选择模型与参数的过程也限制了对泛化能力的直接判断。

类别分布明显不均衡，snare缺少验证与测试实例，scissors召回较低；仍需按类别检查漏检、遮挡和细小部件。转换存在少量连接线与栅格化误差，报告没有额外计算基于原始Mask的实例面积加权Dice或预测IoU。

预测图片仅展示模型输出，未额外导出预测视频。完整20张样例、原始预测JSON及抽样来源保存在本报告assets/目录；定量结论使用完整验证集，图片示例不构成独立性能评估。