CholecInstanceSeg YOLO26-seg 手术器械识别与实例分割综合实验报告

实验日期：2026年11月2日；报告日期：2026年11月3日。三个模型均已完成训练与独立测试，本报告根据本地保存的CSV、配置、日志及真实预测汇编。

实验任务与数据划分

任务为识别腹腔镜手术图像中的器械类别，并输出每个器械的独立分割掩膜。比较YOLO26s-seg、YOLO26m-seg、YOLO26l-seg在相同数据划分和训练设置下的精度、资源消耗及推理速度。三组分别从对应的官方COCO预训练权重开始全参数微调。

使用CholecInstanceSeg官方图像、实例JSON和元数据，作者项目：github.com/cai4cai/cholec_instance_seg。数据按视频编号划分，三个集合没有视频编号交集。

集合	视频编号数	图像数	实例数	无器械图像
train	45	26830	42716	2542
val	18	4284	6380	542
test	22	10819	15659	1830

类别与实例分布

ID	英文类别	训练实例	验证实例	测试实例
0	grasper	25698	4017	8701
1	hook	12675	1759	4848
2	irrigator	1189	122	1109
3	clipper	899	99	326
4	bipolar	1762	270	526
5	scissors	450	113	149
6	snare	43	0	0

snare仅有43个训练实例，验证和测试均无该类实例；总体指标不能反映snare的泛化能力。三个集合共41,933张图像、64,755个器械实例。

数据转换、核查与软件环境

每个类别与group_id共同确定一个器械实例。通过Shapely修复并裁剪几何，使用Ultralytics官方merge_multi_segment连接离散轮廓，输出归一化YOLO分割多边形。同类别多个器械分别保留。

独立核查逐张解码输出图像，从实际保存的TXT还原掩膜，核对尺寸、类别、图像配对与实例数。三次训练复用同一套转换结果，本报告没有重新生成数据集副本。

核查项目	结果
图像 / 实例总数	41,933 / 64,755
原始图像尺寸	854×480、1920×1080
未配对 / 转换检查失败	0 / 0
平均 / 面积加权还原IoU	0.99971728 / 0.99989545
最小实例还原IoU	0.87465691
还原IoU低于0.95 / 未解释差异	31个实例 / 0

还原IoU衡量标签表示误差，与模型预测质量分别解释。完整逐实例记录保存在实验归档data/conversion.jsonl。

实际服务器环境

项目	设置
GPU / CPU / 内存	RTX 4090 24GB / i9-14900K / 128GB
操作系统 / Python	Ubuntu 24.04 / 3.12.3
PyTorch / torchvision	2.14.1+cu126 / 0.29.1+cu126
Ultralytics	8.4.190
CUDA运行时 / NVIDIA驱动	12.6 / 580.105.08
PyTorch可见显存	约23.516GiB
执行方式	tmux后台训练，AMP检查通过

训练控制条件与模型规模

三份实际args.yaml共核对114项：111项完全相同，仅model、name、save_dir不同，分别对应模型权重、实验名称和输出目录。

共享参数	实际设置
最大Epoch / patience	150 / 30
imgsz / batch / nbs	640 / 16 / 64
优化器 / 初始学习率	MuSGD / lr0=0.01
momentum / weight_decay	0.9 / 0.0005
warmup_epochs / lrf / cos_lr	3.0 / 0.01 / False
AMP / workers / freeze	True / 8 / 0
seed / deterministic	42 / True
mosaic / close_mosaic	1.0 / 10
fliplr / translate / scale	0.5 / 0.1 / 0.5
mask_ratio / overlap_mask	4 / True
save_period / cache	10 / False

七类别训练结构与权重文件

模型	训练参数量	best.pt大小	最佳轮次
YOLO26s-seg	11.440M	22.25MiB	36
YOLO26m-seg	26.981M	51.96MiB	32
YOLO26l-seg	31.384M	60.49MiB	26

参数量取自七类别训练日志，包含训练期间使用的结构；与官方80类别融合推理模型参数量的统计口径不同。best.pt已在训练正常结束后清理优化器状态。

预热之后梯度累积约4个训练批次。close_mosaic=10按150轮计划在最后10轮关闭，三组均提前停止，均未进入这一阶段。实际训练长度由相同早停规则决定。

训练耗时、显存与检查点对照

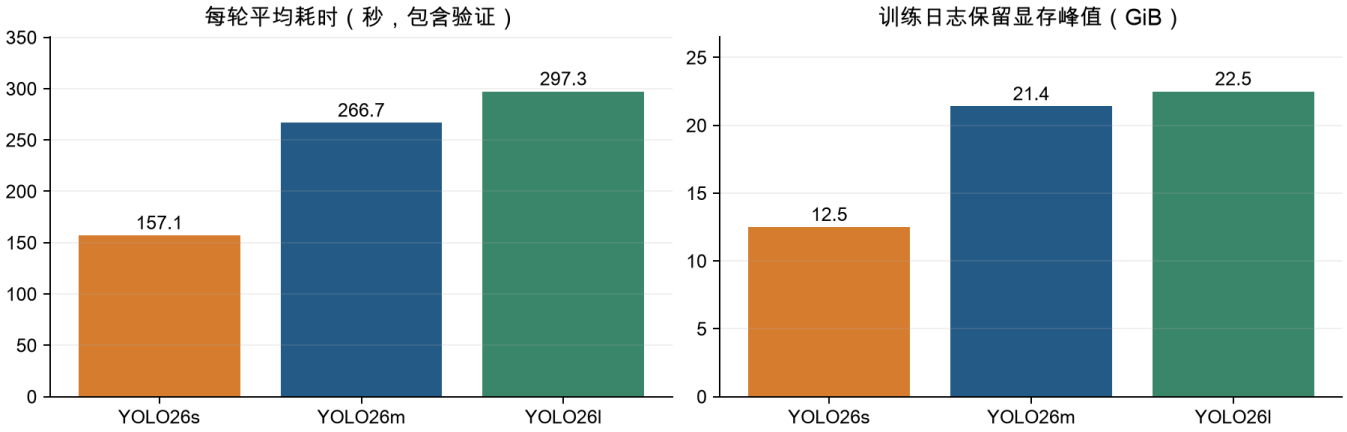


图1：每轮平均耗时包含训练与验证；显存为完整训练日志中的最高保留显存显示值，有舍入。

项目	YOLO26s	YOLO26m	YOLO26l
完成轮数 / 最佳轮次	66 / 36	62 / 32	56 / 26
训练累计时间（小时）	2.880	4.594	4.625
平均每轮（秒）	157.09	266.75	297.32
每轮中位耗时（秒）	156.80	266.30	296.90
保留显存峰值（GiB）	12.5	21.4	22.5
训练批次总数	110,682	103,974	93,912
图像呈现次数	1,770,780	1,663,460	1,502,480
阶段检查点数量	7	7	6
费用折算（元）	9.82	15.67	15.77

三次正式训练累计约12.10小时；按3.41元/小时折算约41.26元。上传、环境安装、预先测量、独立测试、备份和空闲时间另计，不能将这个折算值当作平台总账单。

每轮训练1,677个批次、验证134个批次。预热期间累积步长变化，训练批次数不能直接当作优化器更新次数。small平均每轮耗时较短；large与medium总耗时接近，但large完成轮数更少。

最佳模型验证集指标对照

三组均根据验证fitness选择best.pt。当前分割fitness为Box与Mask mAP50-95之和，最佳轮次分别为small第36轮、medium第32轮、large第26轮。下表取对应轮次CSV原始精度，完整验证集为4,284张图像、6,380个实例。

指标	YOLO26s	YOLO26m	YOLO26l
Box Precision	0.95170	0.97058	0.96037
Box Recall	0.83091	0.84221	0.84905
Box mAP50	0.88758	0.91397	0.91125
Box mAP50-95	0.79621	0.82479	0.81624
Mask Precision	0.95304	0.96976	0.96093
Mask Recall	0.83027	0.84120	0.84631
Mask mAP50	0.88575	0.91084	0.90765
Mask mAP50-95	0.71575	0.74391	0.73870

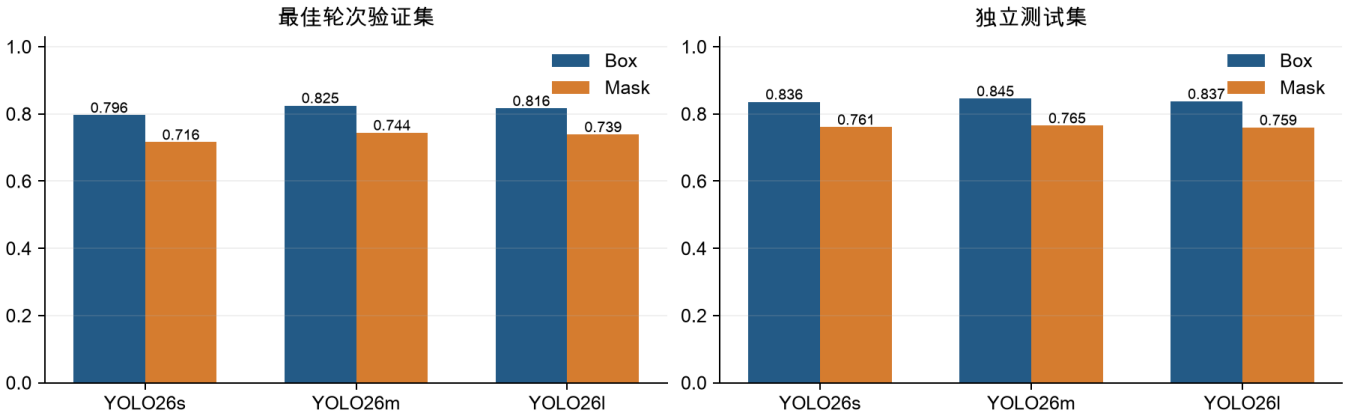


图2：三个模型在验证集与独立测试集上的Box、Mask mAP50-95。纵轴从0开始，数值标签保留三位小数。

当前验证Mask mAP50-95以medium最高，比small高约2.816个百分点，比large高约0.521个百分点。较高Precision伴随较低Recall，表示漏检仍需结合逐类别结果判断。

表格中的Precision和Recall来自框架评估选定的工作点，与预测样例固定conf=0.25的工作点不同。mAP反映跨置信度排序的性能。

独立测试集指标与差值

三种模型各自采用验证集选出的best.pt，对同一10,819张测试图像、15,659个实例进行评估；imgsz=640、batch=16、相同入口与环境。small和medium的测试在先前对照流程中完成，large训练完成后单独测试。

指标	YOLO26s	YOLO26m	YOLO26l
Box Precision	0.93537	0.95092	0.91992
Box Recall	0.88338	0.87917	0.88456
Box mAP50	0.93016	0.93611	0.92865
Box mAP50-95	0.83570	0.84526	0.83708
Mask Precision	0.93485	0.95141	0.92917
Mask Recall	0.87939	0.87627	0.87094
Mask mAP50	0.92682	0.93283	0.92490
Mask mAP50-95	0.76066	0.76502	0.75943

相对medium的变化

指标差值（百分点）	small - medium	large - medium
Box mAP50-95	-0.957	-0.818
Mask mAP50-95	-0.436	-0.559
Mask Precision	-1.656	-2.225
Mask Recall	+0.312	-0.533

测试Mask mAP50-95分别为small 0.76066、medium 0.76502、large 0.75943。当前单次实验未观察到large带来总体分割提升。测试与验证来自不同视频集合，分数差异不能解释为测试时进行了额外训练。

测试集未参与梯度更新或逐轮早停；本报告使用这些测试结果比较模型，后续若据此选型，应另留外部数据确认泛化。只有一个训练种子，不能宣称精度差异具有统计显著性。

逐类别分割表现对照

下表为best.pt原生日志中的逐类别Mask mAP50-95，仅保留日志显示精度。snare没有验证或测试实例，没有列入表格。

验证集逐类别Mask mAP50-95

类别	实例数	YOLO26s	YOLO26m	YOLO26l
grasper	4017	0.688	0.703	0.697
hook	1759	0.879	0.882	0.881
irrigator	122	0.842	0.854	0.847
clipper	99	0.874	0.873	0.879
bipolar	270	0.598	0.630	0.618
scissors	113	0.413	0.524	0.511

测试集逐类别Mask mAP50-95

类别	实例数	YOLO26s	YOLO26m	YOLO26l
grasper	8701	0.645	0.652	0.652
hook	4848	0.882	0.880	0.882
irrigator	1109	0.796	0.804	0.806
clipper	326	0.863	0.867	0.855
bipolar	526	0.682	0.691	0.683
scissors	149	0.696	0.696	0.679

剪刀类别的召回

集合	YOLO26s	YOLO26m	YOLO26l
验证集	0.387	0.432	0.442
测试集	0.738	0.738	0.698

scissors在验证集中是明显短板，三个模型的验证召回均低于0.45；测试召回更高，说明类别表现受视频划分影响。不能仅根据实例数就把失败原因归结为样本不足。

Ultralytics逐类别JSON中无前缀mAP字段表示检测框指标；本页Mask mAP来自原生日志。完整整体指标仍使用原始JSON精度。

收敛曲线与提前停止

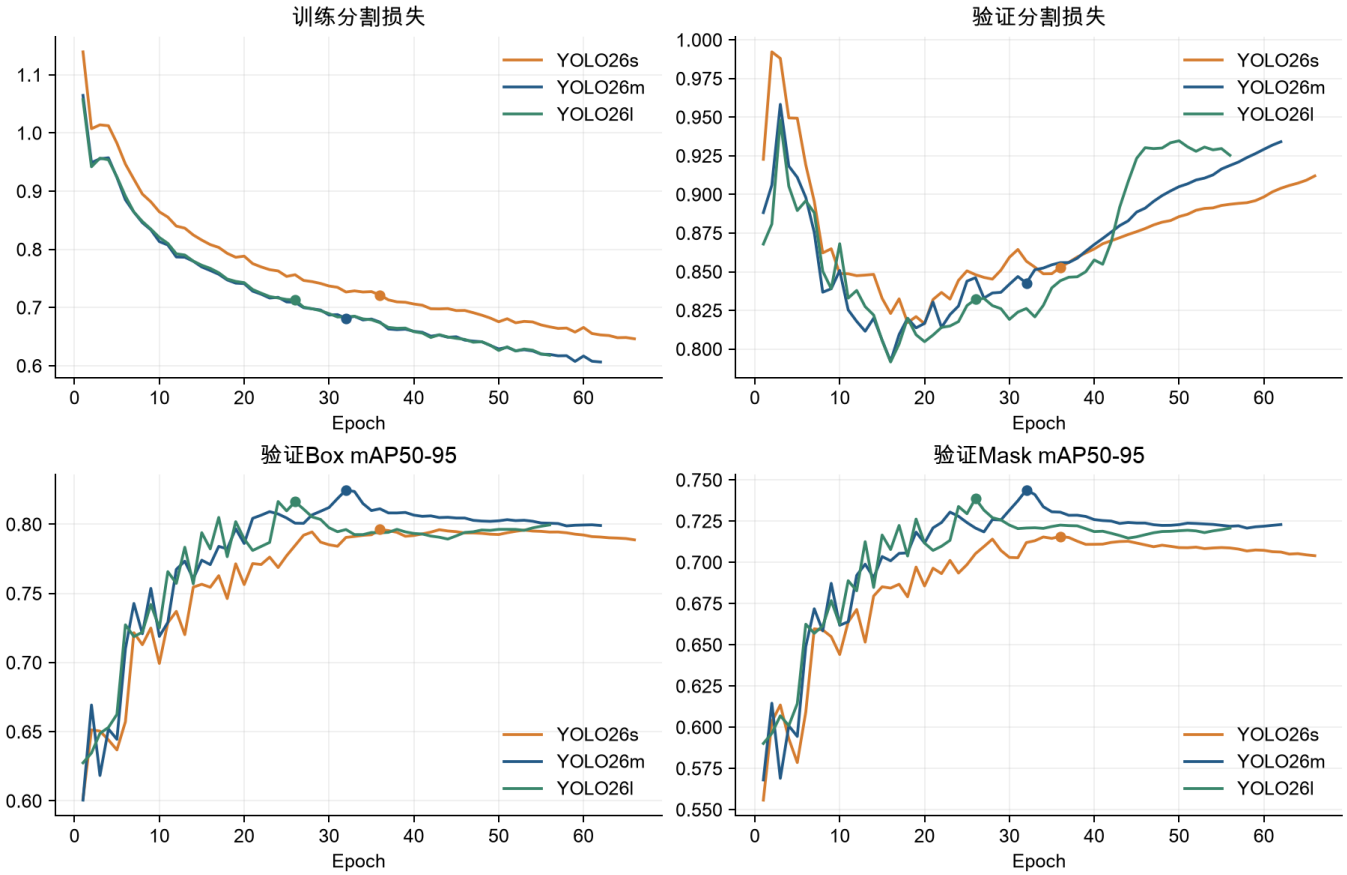


图3：三次完整训练的Mask损失与验证mAP曲线。圆点表示各自最佳轮次，曲线没有填补或平滑。

模型	最佳→末轮	训练Mask Loss	验证Mask Loss	验证Mask mAP50-95
YOLO26s	36→66	0.7216→0.6464	0.8528→0.9120	0.7157→0.7040
YOLO26m	32→62	0.6815→0.6065	0.8427→0.9341	0.7439→0.7229
YOLO26l	26→56	0.7132→0.6180	0.8321→0.9253	0.7387→0.7208

三组在最佳轮次之后，训练分割损失继续下降，验证分割损失上升，验证Mask mAP50-95下降，呈现过拟合迹象。均在最佳轮次后30轮正常提前停止。最后一轮权重与最佳权重分别保存，测试采用最佳权重。

这些现象支持保留早停和验证集选模。当前实验不能单独量化数据量、类别不均衡、模型规模或标注表示误差各自的作用，也不能把某次最佳轮数当作所有模型的固定训练长度。

GPU推理速度与精度取舍

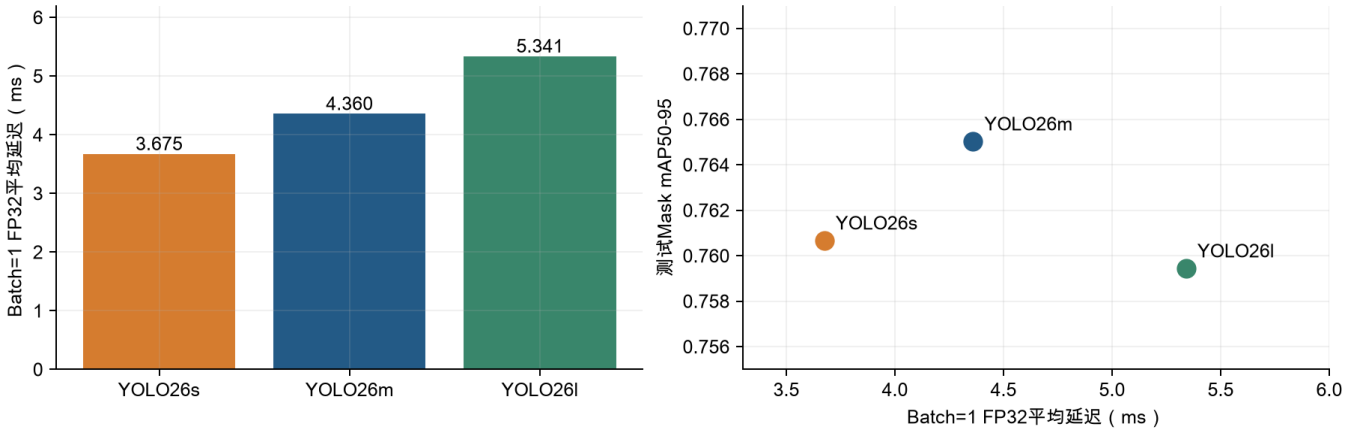


图4：Batch=1、FP32平均延迟与测试分割精度。右图纵轴缩放用于展示小幅差异，应结合数值和单次实验限制解读。

项目	YOLO26s	YOLO26m	YOLO26l
样本 / 预热	50 / 10	50 / 10	50 / 10
平均延迟（ms）	3.675	4.360	5.341
中位延迟（ms）	3.676	4.345	5.426
P95延迟（ms）	3.804	4.571	5.508
平均延迟折算FPS	272.09	229.36	187.24
分配显存峰值（GiB）	0.1138	0.2007	0.2303
保留显存峰值（GiB）	0.1406	0.2344	0.2656

使用同一RTX 4090、相同50张预先解码验证图像、10张预热、imgsz=640、FP32和CUDA同步逐张计时，包含预处理、推理及后处理，排除解码、绘制和视频编码。样本来源清单已核对一致。small、medium在同一流程依次计时，large在较晚时段单独计时。

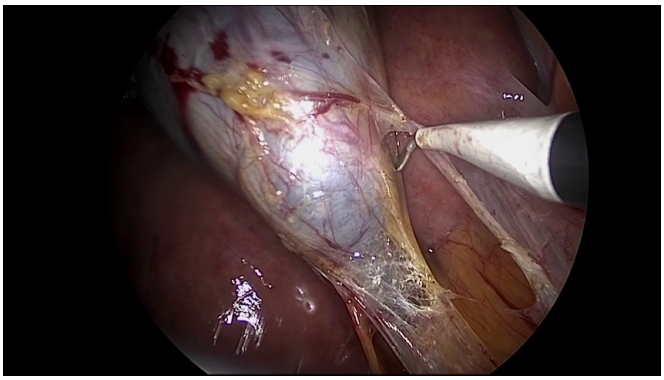
当前small平均延迟比medium低约15.71%，large比medium高约22.50%。每个模型只计时一组，没有重复测量置信区间，折算FPS不能当作完整视频处理速度。

相同图像的预测对照（一）

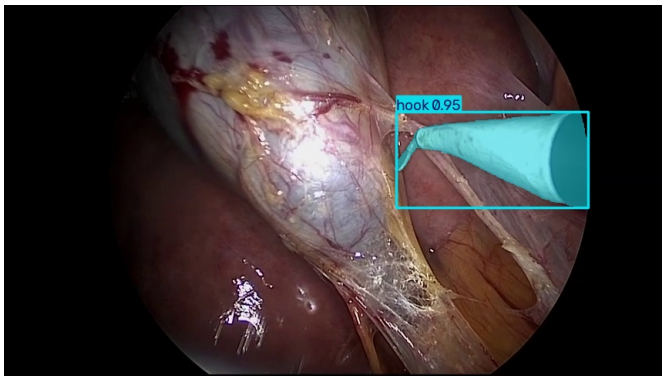
沿用先前随机种子42选出的20张验证样本，按顺序展示前4张。均为各自best.pt，imgsz=640、conf=0.25、Mac CPU预测；显示真实模型输出，不包含人工修正。

样例01：01_VID23_t50_full_t50_VID23_000208.png

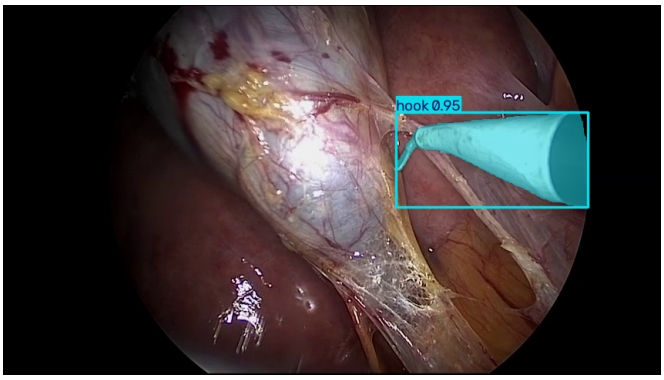
原始图像



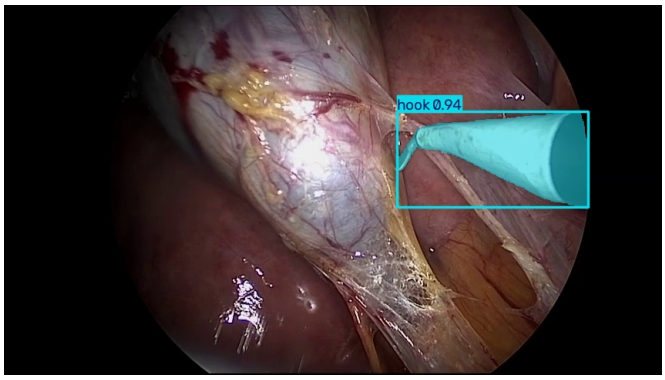
YOLO26s-seg



YOLO26m-seg

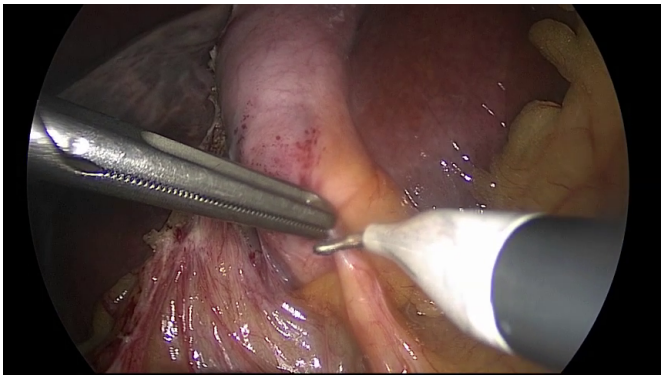


YOLO26l-seg

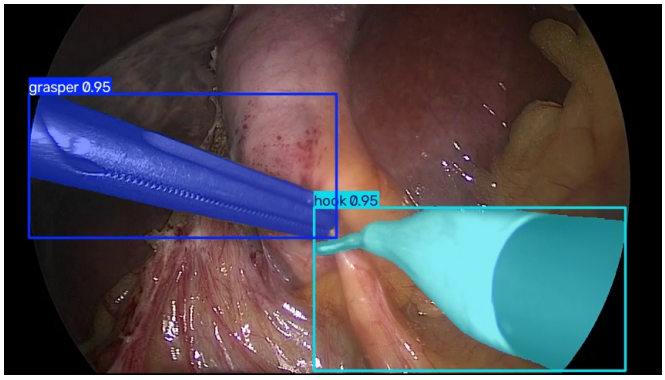


样例02：02_VID11_t80_sparse_t80_VID11_000270.png

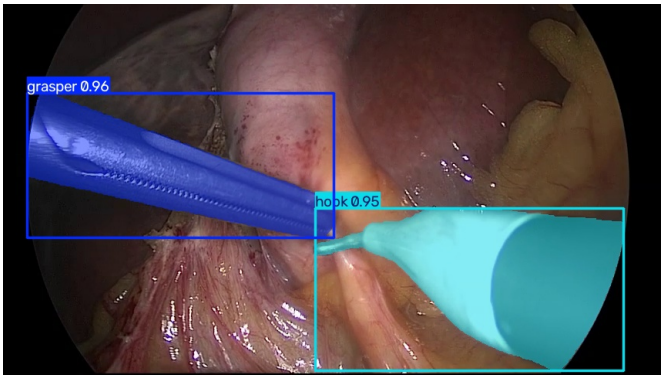
原始图像



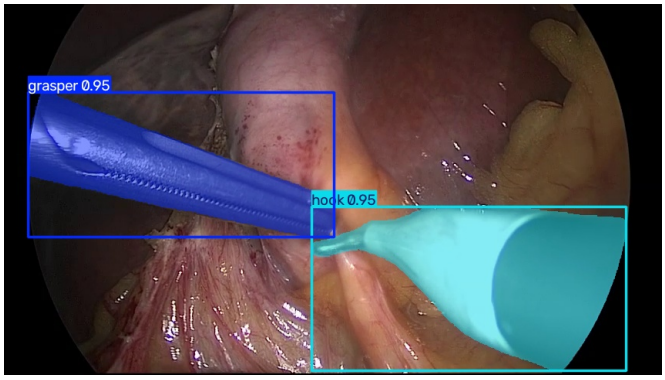
YOLO26s-seg



YOLO26m-seg



YOLO26l-seg

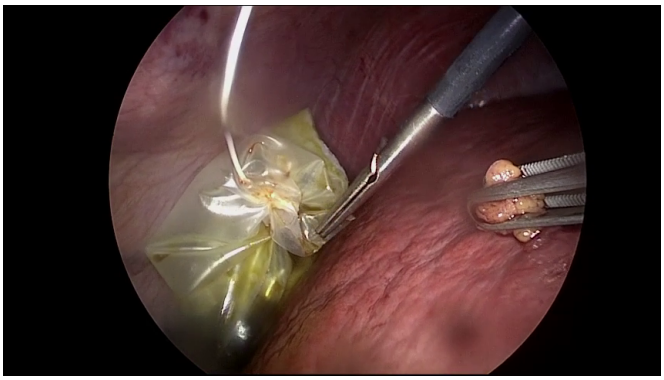


相同图像的预测对照（二）

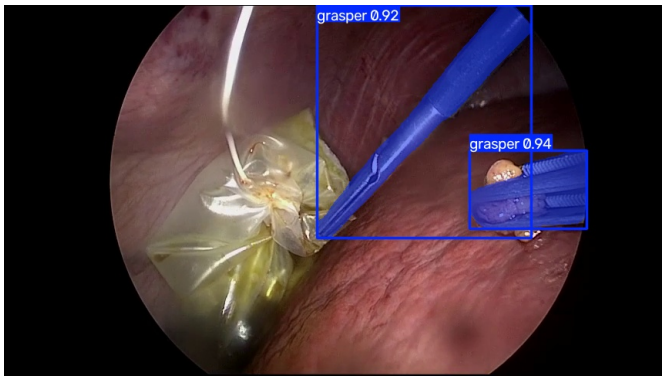
沿用先前随机种子42选出的20张验证样本，按顺序展示前4张。均为各自best.pt，imgsz=640、conf=0.25、Mac CPU预测；显示真实模型输出，不包含人工修正。

样例03：03_VID23_t50_full_t50_VID23_001549.png

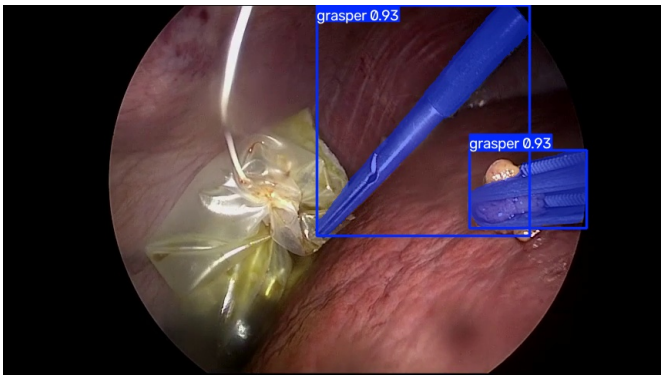
原始图像



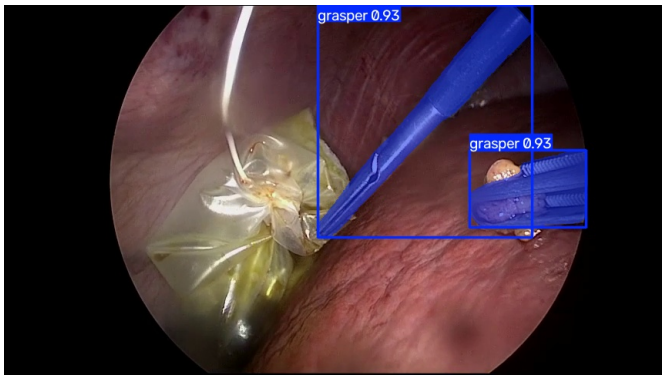
YOLO26s-seg



YOLO26m-seg

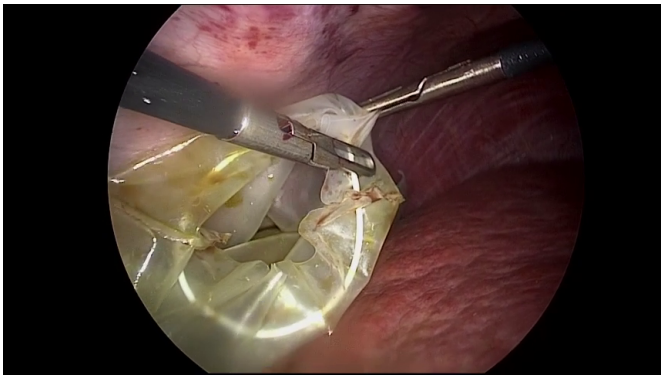


YOLO26l-seg

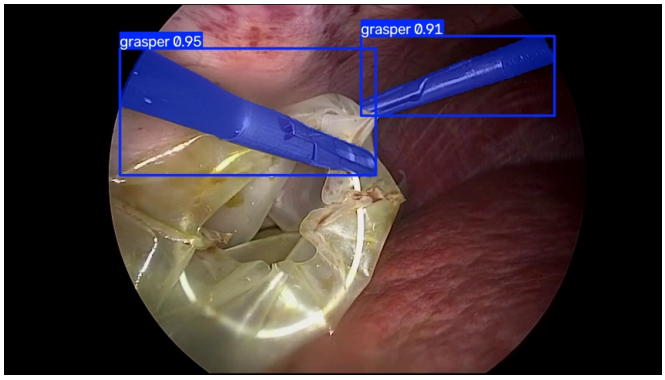


样例04：04_VID23_t50_full_t50_VID23_001302.png

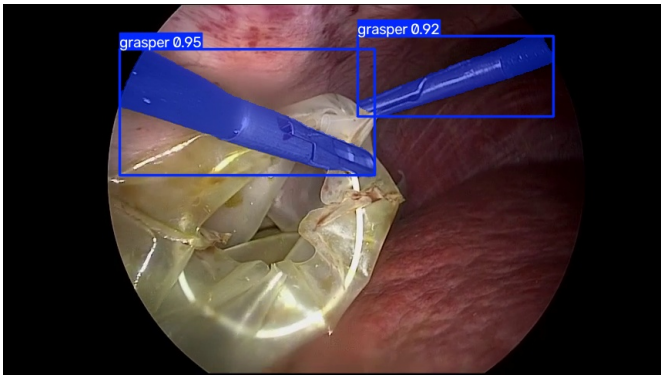
原始图像



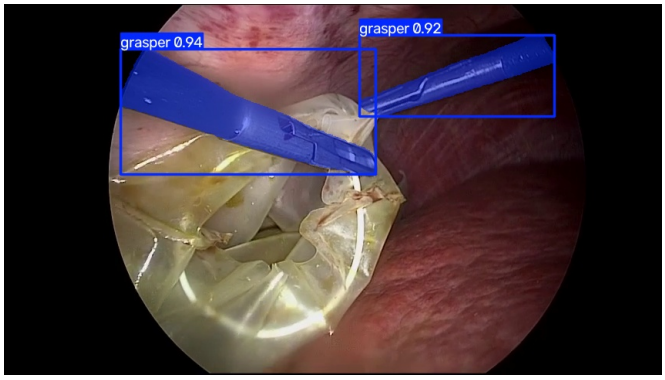
YOLO26s-seg



YOLO26m-seg



YOLO26l-seg



结果解释与适用范围

在当前划分和统一训练设置下，medium的验证及测试Mask mAP50-95均最高；small训练与推理开销较低，测试分割指标与medium相差约0.436个百分点。large增加了参数量和推理耗时，本次未带来总体分割提升。

精度优先时，当前结果支持使用medium作为候选；资源和延迟优先时，small具有实际价值。large在某些类别上有局部变化，但当前整体证据不足以支持用它替换medium。以上判断限于本次单种子实验。

解释边界

三次使用相同batch=16，结果无法回答增大batch是否会改善质量；数据规模没有变化，结果也无法量化扩大数据集的收益。模型容量变化伴随预训练权重及实际早停轮数变化，当前实验比较的是完整微调方案的最终表现。

当前缺少多随机种子重复实验、外部医院或设备测试，以及snare的验证和测试实例。预测示例属于定性展示，没有逐实例人工误差标注，不能据此判断具体模型对所有细节的优劣。

复现与材料索引

材料	本地位置（相对于yolofinetune）
三次完整实验	experiments/2026-11-02_yolo26{s,m,l}_cholec/
small、medium上传材料	releases/2026-11-02_yolo26s_m_comparison/
large上传材料	releases/2026-11-02_yolo26l_comparison/
本报告与支撑指标	reports/2026-11-03_yolo26_s_m_l_comparison/
原始数据与YOLO训练数据	datasets/cholecinstanceseg/

本报告目录的source_metrics/分别保存三组CSV、实际配置、最佳验证指标、独立测试及计时JSON；assets/包含原始数值汇编、四幅图表和固定预测对照。完整阶段权重、原生日志与环境依赖保存在各自实验归档。

```
.venv/bin/python scripts/run.py train \
--config configs/rtx4090.yaml --batch 16 \
--weights weights/yolo26m-seg.pt --name yolo26m-reproduce
```

切换模型时同时更换对应预训练权重和实验名称。复现需要先按项目说明准备数据及CUDA环境。本报告生成过程只读取本地已完成实验，没有启动新训练或远程发布。